

(MCMC, Markov Chain Monte Carlo)

WB- 9/11

## MONTICARLO POR CADENA DE MARKOV

↳ problema: estimar  $\mu = E_{\pi}[g(x)]$

generar  $\vec{x}_1, \dots, \vec{x}_n \sim \pi$  y calcular  $\hat{\mu} = \frac{1}{n} \sum_{i=1}^n g(x_i)$

Como aplicar el metodo montecarlo?

CONSTRUIR U CADENA DE MARKOV TAL QUE  $\lim_{t \rightarrow \infty} \pi_t = \pi$


$x_0 \sim x \dots \sim x_t$   
?  
 $\pi_1 \approx \pi \quad \pi_2 \approx \pi \quad \pi_t \approx \pi$

↳ si se cumplen las condiciones necesarias, se tendra que  $\pi$  sera estacionaria para la cadena de Markov

Entonces, para aplicar el metodo:

1. Obtener realizaciones de la cadena de Markov hasta un cierto  $t$  suficientemente grande (con VALORES INICIALES INDEPENDIENTES)
2. Recuperar los valores  $x_1, \dots, x_n$  de la variable  $X_t$  para cada una de esas realizaciones.

3.  $\hat{\mu} = \frac{1}{n} \sum_{i=1}^n y(x_i)$



En general, los valores  $x_1, \dots, x_n$  se toman de una unica realizacion de la cadena de Markov.

**Definición 1** Un proceso estocástico es una colección de variables aleatorias  $\{X_t\}_{t \in \mathcal{T}}$  sobre un mismo espacio de probabilidad, donde  $\mathcal{T}$  es cualquier conjunto de índices.

El conjunto  $E$  de posibles valores de cada  $X_t$  (que asumimos que es independiente de  $t$ ) se llama el **espacio de estados del proceso**.

El conjunto de índices  $\mathcal{T}$  se toma a menudo como un subconjunto numerable o continuo de  $\mathbb{R}$ , considerando de esa forma un proceso aleatorio como una variable aleatoria que evoluciona a lo largo del tiempo.

**Definición 2** Una cadena de Markov de tiempo discreto es un proceso estocástico  $X = \{X_t\}_{t \in \mathbb{Z}_{\geq 0}}$  que cumple la propiedad de Markov:

$$\rightarrow \mathbb{P}(X_{t+1} | X_0, \dots, X_t) = \mathbb{P}(X_{t+1} | X_t), \quad \forall t \in \mathbb{Z}_{\geq 0}$$

Una cadena de Markov es **homogénea** en el tiempo si las probabilidades anteriores no dependen del índice  $t$ :

$$\rightarrow \mathbb{P}(X_{t+1} | X_t) = \mathbb{P}(X_1 | X_0), \quad \forall t \in \mathbb{Z}_{\geq 0}$$

En lo que sigue solo consideraremos cadenas de Markov de tiempo discreto homogéneas. La distribución de una cadena de Markov homogénea viene determinada por

1. La **distribución marginal** de  $X_0$ , llamada **distribución inicial**.
2. La **distribución condicional**  $X_{t+1} | X_t$ , llamada **distribución de transición**.

Si el espacio de estados de la cadena de Markov es finito,  $E = \{x_1, \dots, x_d\}$ , entonces la distribución inicial se puede representar como un vector  $(p_1, \dots, p_d) \in \mathbb{R}_{\geq 0}^d$  tal que

$$\sum_{i=1}^d p_i = 1$$

$$\mathbb{P}(X_0 = x_i) = p_i, \quad \forall i = 1, \dots, d$$

y la distribución de transición como una matriz  $P = (p_{ij})_{i,j=1,\dots,d} \in \mathbb{R}_{\geq 0}^{d \times d}$  tal que

$$\sum_{j=1}^d p_{ij} = 1, \quad \forall i = 1, \dots, d$$

$$\mathbb{P}(X_{t+1} = x_j | X_t = x_i) = p_{ij}, \quad \forall i, j = 1, \dots, d$$

Si el espacio de estados es infinito numerable, entonces las distribuciones inicial y de transición se pueden representar como un vector y una matriz infinitas, respectivamente.

Si el espacio de estados es continuo, entonces debemos pensar en la distribución inicial como una distribución no condicional y en la distribución de transición como una distribución condicional.

## E finito o numerable

**Proposición 3** Denotemos por  $p_{ij}^{(t)}$  la probabilidad de que una cadena de Markov  $\{X_t\}_{t \in \mathbb{Z}_{\geq 0}}$  pase del estado  $i$  al estado  $j$  en  $t$  unidades de tiempo, esto es

$$\longrightarrow p_{ij}^{(t)} = \mathbb{P}(X_t = j \mid X_0 = i)$$

Las ecuaciones de Chapman-Kolmogorov establecen que

$$\longrightarrow p_{ij}^{(t+t')} = \sum_{k \in E} p_{ik}^{(t)} p_{kj}^{(t')}, \quad \forall i, j \in E, \forall t, t' \geq 0$$

Para las cadenas de Markov con espacio de estado finito o infinito numerable, denotando por  $P^{(t)}$  la matriz de probabilidades de transición en  $t$  pasos, las ecuaciones anteriores se traducen en que  $P^{(t)}$  se puede obtener multiplicando  $P$  consigo misma  $t$  veces.

**Definición 4** Sea  $X$  una cadena de Markov con espacio de estados  $E$  y matriz de transición  $P$ . Sea  $\pi = (\pi_i)_{i \in E}$  una distribución de probabilidad sobre  $E$ , es decir,

$$0 \leq \pi_i \leq 1, \forall i \in E \quad \text{y} \quad \sum_{i \in E} \pi_i = 1$$

- $\pi$  es invariante o estacionaria para  $X$  si

$$\longrightarrow X_0 \sim \pi \Rightarrow X_t \sim \pi, \quad \forall t \in \mathbb{Z}_{\geq 0}$$

Es fácil comprobar que esto se verifica si y solo si  $\pi = \pi P$ .

- $\pi$  es una distribución límite de  $X$  si

$$\pi_j = \lim_{t \rightarrow +\infty} \mathbb{P}(X_t = j \mid X_0 = i), \quad \forall i, j \in E$$

## Definición 5

1. Un estado  $j$  se dice que es accesible desde un estado  $i$  si  $p_{ij}^{(t)} > 0$ , para algún  $t \geq 0$ .
2. Dos estados  $i$  y  $j$  se dice que se comunican,  $i \leftrightarrow j$ , si cada uno es accesible desde el otro.

**Proposición 6** La relación de comunicación es una relación de equivalencia sobre el espacio de estados de la cadena de Markov. Es decir,

1. Para todo estado  $i \in E$ ,  $i \leftrightarrow i$ .
2. Para cualesquiera estados  $i, j \in E$ , si  $i \leftrightarrow j$ , entonces  $j \leftrightarrow i$ .
3. Para cualesquiera estados  $i, j, k \in E$ , si  $i \leftrightarrow j$  y  $j \leftrightarrow k$ , entonces  $i \leftrightarrow k$ .

Dos estados que se comunican se dice que están en la misma clase (de equivalencia).

**Definición 7** Una cadena de Markov se dice que es irreducible si posee una única clase. Es decir, si todos sus estados se comunican entre sí.

**Definición 8** Un estado  $i$  se dice que tiene periodo  $n$  si

$$n = \text{mcd}\{t > 0 \mid p_{ii}^{(t)} > 0\}$$

Si  $n > 1$  el estado se dice que es periódico y si  $n = 1$  se dice que es aperiódico.

**Proposición 9**

1. Todos los estados de una misma clase comunicante tienen el mismo periodo.
2. En una cadena de Markov irreducible todos los estados tienen el mismo periodo.

**Definición 10** La variable aleatoria  $\tau(i)$  que dada una cadena de Markov  $\{X_t\}_{t \in \mathbb{Z}_{\geq 0}}$  cuenta el mínimo número de transiciones necesarias para alcanzar el estado  $i$  se define como

$$\tau(i) = \inf\{t \geq 1 \mid X_t = i\}$$

donde  $\tau(i) = +\infty$  si el conjunto anterior es el conjunto vacío.

**Teorema 11** Sea  $X$  una cadena de Markov irreducible y aperiódica con espacio de estados finito  $E$ . Entonces,

1.  $X$  tiene una única distribución invariante  $\pi = (\pi_i)_{i \in E}$ .
2.  $\pi$  es distribución límite de  $X$ .
3.  $\pi_i = \frac{1}{m_i}$  para todo  $i \in E$ , donde  $m_i = \mathbb{E}[\tau(i) \mid X_0 = i]$ .

**Definición 12**

1. Un estado  $i$  se dice que es recurrente si  $\mathbb{P}(\tau(i) < +\infty \mid X_0 = i) = 1$ , en caso contrario se dice que es transitorio.
2. Un estado recurrente  $i$  se dice que es positivo recurrente si  $\mathbb{E}[\tau(i) \mid X_0 = i] < +\infty$ , en caso contrario se dice que es cero recurrente.

**Proposición 13**

1. La recurrencia (positiva) y la transitoriedad son propiedades de clase.
2. En una cadena de Markov con espacio de estados finito todo estado recurrente es positivo recurrente.
3. Todos los estados de una cadena de Markov irreducible con espacio de estados finito son positivo recurrentes.

**Teorema 14** Sea  $X$  una cadena de Markov irreducible y aperiódica con espacio de estados infinito numerable  $E$ . Entonces ocurre uno de los siguientes casos:

- Todos los estados son transitorios y

$$\lim_{t \rightarrow +\infty} \mathbb{P}(X_t = j \mid X_0 = i) = 0, \quad \forall i, j \in E$$

- Todos los estados son cero recurrentes y

$$\lim_{t \rightarrow +\infty} \mathbb{P}(X_t = j \mid X_0 = i) = 0, \quad \forall i, j \in E$$

- Todo los estados son positivo recurrentes y

1.  $X$  tiene una única distribución invariante  $\pi = (\pi_i)_{i \in E}$ .
2.  $\pi$  es distribución límite de  $X$ .
3.  $\pi_i = \frac{1}{m_i} > 0$  para todo  $i \in E$ , donde  $m_i = \mathbb{E}[\tau(i) \mid X_0 = i]$ .

**Definición 15** Una cadena de Markov  $\{X_t\}_{t \in \mathbb{Z}_{\geq 0}}$  estacionaria se dice que es reversible si

$$\mathbb{P}(X_{t+1} = i \mid X_{t+2} = j) = \mathbb{P}(X_{t+1} = j \mid X_t = i)$$

para todo  $i \in E$ .

**Definición 16** La matriz de transición  $P$  de una cadena de Markov se dice que está en balance detallado con una distribución de probabilidad  $\pi$  si

$$\pi_i p_{ij} = \pi_j p_{ji}, \quad \forall i, j \in E$$

**Teorema 17** Sea  $X$  una cadena de Markov cuya matriz de transición está en balance detallado con una distribución de probabilidad  $\pi$ . Entonces,

1.  $\pi$  es la distribución invariante de  $X$ .
2. Tomando  $\pi$  como distribución inicial,  $X$  es reversible.

**Teorema 18** Sean  $\{X_t\}_{t \in \mathbb{Z}_{\geq 0}}$  una cadena de Markov irreducible con distribución estacionaria  $\pi$  y  $g: E \rightarrow \mathbb{R}$  una función acotada. Entonces,

$$\lim_{n \rightarrow +\infty} \frac{1}{n} \sum_{t=0}^n g(x_t) = \sum_{i \in E} g(i) \pi_i = \mathbb{E}_{\pi}[g(X)]$$

con probabilidad 1, para cualquier realización  $(x_t)_{t=0, \dots, n}$  de la cadena de Markov.

## ***E* continuo**

Asumimos  $E = \mathbb{R}^d$  y que la distribución de transición de la cadena de Markov se expresa mediante un *núcleo de transición*  $K: \mathbb{R}^d \times \mathbb{R}^d \rightarrow \mathbb{R}_{\geq 0}$ , de manera que

$$\mathbb{P}(X_{t+1} \in A \mid X_t = x) = \int_A K(x, y) dy$$

para todo conjunto de Borel  $A \subseteq \mathbb{R}^d$ . Es decir,  $K(x, \cdot)$  es justamente la función de densidad condicionada de  $X_{t+1}$  dado  $X_t = x$ .

**Proposición 19** *La transición en  $t$  unidades de tiempo de la cadena de Markov viene dada por*

$$\mathbb{P}(X_t \in A \mid X_0 = x_0) = \int_A K^{(t)}(x_0, x_t) dx_t$$

donde

$$K^{(t)}(x_0, x_t) = \int_{\mathbb{R}^d} \cdots \int_{\mathbb{R}^d} K(x_0, x_1) \cdots K(x_{t-1}, x_t) dx_{t-1} \cdots dx_1$$

Las ecuaciones de Chapman-Kolmogorov establecen que

$$K^{(t+t')}(x, y) = \int_{\mathbb{R}^d} K^{(t)}(x, z) K^{(t')}(z, y) dz$$

**Definición 20** *Una distribución de probabilidad  $\pi$  con función de densidad  $f_\pi$  es invariante o estacionaria para el núcleo de transición  $K$  si*

$$f_\pi(y) = \int_{\mathbb{R}^d} f_\pi(x) K(x, y) dx, \quad \forall y \in \mathbb{R}^d$$

Si  $\{X_t\}_{t \in \mathbb{Z}_{\geq 0}}$  es una cadena de Markov con distribución invariante  $\pi$  y tomamos  $\pi$  como su distribución inicial, entonces  $X_t \sim \pi$  para todo  $t \in \mathbb{Z}_{\geq 0}$ .

**Definición 21** *Dada una medida  $\varphi$  sobre  $\mathbb{R}^d$ , una cadena de Markov se dice que es  $\varphi$ -irreducible si para todo conjunto de Borel  $A \subseteq \mathbb{R}^d$  tal que  $\varphi(A) > 0$  y para todo  $x \in \mathbb{R}^d$  existe un  $t > 0$  tal que  $\mathbb{P}(X_t \in A \mid X_0 = x) > 0$ .*

**Definición 22** *Una cadena de Markov con distribución invariante  $\pi$  se dice que es aperiódica si no existen  $n > 1$  y subconjuntos de Borel disjuntos  $A_1, \dots, A_n \subseteq \mathbb{R}^d$  tales que:*

1.  $\pi(A_i) > 0$ , para todo  $i = 1, \dots, n$ .
2.  $\mathbb{P}(X_{t+1} \in A_{i+1} \mid X_t \in A_i) = 1$ , para todo  $i = 1, \dots, n-1$  y  $\mathbb{P}(X_{t+1} \in A_1 \mid X_t \in A_n) = 1$ .

**Definición 23** El número de visitas de una cadena de Markov a un conjunto  $A \subseteq \mathbb{R}^d$  viene dado por

$$V(A) = \sum_{t=0}^{+\infty} \mathbb{1}(X_t \in A)$$

**Definición 24**

1. Un conjunto de Borel  $A \subseteq \mathbb{R}^d$  se dice que es recurrente si para todo  $x \in A$

$$\mathbb{E}[V(A) \mid X_0 = x] = +\infty$$

2. Una cadena de Markov se dice que es recurrente si

- a) La cadena es  $\varphi$ -irreducible para alguna medida  $\varphi$ .
- b) Todo conjunto de Borel  $A \subseteq \mathbb{R}^d$  con  $\varphi(A) > 0$  es recurrente.

**Definición 25**

1. Un conjunto de Borel  $A \subseteq \mathbb{R}^d$  se dice que es Harris-recurrente si para todo  $x \in A$

$$\mathbb{P}(V(A) = +\infty \mid X_0 = x) = 1$$

2. Una cadena de Markov se dice que es Harris-recurrente si

- a) La cadena es  $\varphi$ -irreducible para alguna medida  $\varphi$ .
- b) Todo conjunto de Borel  $A \subseteq \mathbb{R}^d$  con  $\varphi(A) > 0$  es Harris-recurrente.

**Proposición 26** Toda cadena de Markov  $\varphi$ -irreducible que tenga una distribución invariante es recurrente.

**Definición 27** La distancia de variación total entre dos distribuciones de probabilidad  $\pi_1$  y  $\pi_2$  se define como

$$\|\pi_1 - \pi_2\| = \sup_{A \subseteq \mathbb{R}^d} |\pi_1(A) - \pi_2(A)|$$

**Teorema 28** Si una cadena de Markov con función núcleo  $K$  es  $\varphi$ -irreducible y aperiódica y tiene distribución invariante  $\pi$ , entonces para  $\pi$ -casi todo  $x \in \mathbb{R}^d$  se tiene que

$$\lim_{t \rightarrow +\infty} \|K^{(t)}(x, \cdot) - \pi\| = 0$$

En particular,  $\lim_{t \rightarrow +\infty} \mathbb{P}(X_t \in A \mid X_0 = x) = \pi(A)$ , para todo conjunto de Borel  $A \subseteq \mathbb{R}^d$ .

Si la cadena es Harris-recurrente, entonces el resultado se da para todo  $x \in \mathbb{R}^d$ .

**Definición 29** Un núcleo de transición  $K$  se dice que está en balance detallado con una distribución  $\pi$  con función de densidad  $f_\pi$  si

$$f_\pi(x)K(x, y) = f_\pi(y)K(y, x)$$

para todo  $x, y \in \mathbb{R}^d$ .

**Teorema 30** Sea  $X$  una cadena de Markov cuyo núcleo de transición está en balance detallado con una distribución de probabilidad  $\pi$ . Entonces,

1.  $\pi$  es la única distribución invariante de  $X$ .
2. Tomando  $\pi$  como distribución inicial,  $X$  es reversible.

**Teorema 31** Sean  $\{X_t\}_{t \in \mathbb{Z}_{\geq 0}}$  una cadena de Markov  $\varphi$ -irreducible con distribución estacionaria  $\pi$  y  $g: \mathbb{R}^d \rightarrow \mathbb{R}$  una función  $\pi$ -integrable. Entonces, para  $\pi$ -casi todo  $x_0 \in \mathbb{R}^d$

$$\lim_{n \rightarrow +\infty} \frac{1}{n} \sum_{t=0}^n g(x_t) = \int_{\mathbb{R}^d} g(x) f_\pi(x) dx = \mathbb{E}_\pi[g(X)]$$

con probabilidad 1 para cualquier realización  $\{x_t\}_{t=0, \dots, n}$  de la cadena de Markov.

Si la cadena es Harris-recurrente, entonces el resultado se verifica para todo  $x_0 \in \mathbb{R}^d$ .